

PROYECTO FINAL: ANÁLISIS DE VENTAS EN VIDEOJUEGOS

POR: ESTEFANÍA FERNANDA VÁZQUEZ OSORNO

INTRODUCCIÓN

¿Cómo sabe una empresa de videojuegos como Nintendo o Rockstar cuántas copias debe mandar a Europa o Asia si solo tiene datos de lo que pasó en Estados Unidos? Lanzar juegos sin datos es como apostar en un casino...

RECOPIACIÓN DE DATOS

Para este proyecto, se usó el dataset “Video Games Sales”, extraído de Kaggle, el dataset contaba con los siguientes atributos:

Rank	Name	Platform	Year	Genre	Publisher	NA_Sales	EU_Sales	JP_Sales	Other_Sales	Global_Sales
1	Wii Sports	Wii	2006	Sports	Nintendo	41.49	29.02	3.77	8.46	82.74
2	Super Mario B	NES	1985	Platform	Nintendo	29.08	3.58	6.81	0.77	40.24
3	Mario Kart Wii	Wii	2008	Racing	Nintendo	15.85	12.88	3.79	3.31	35.82
4	Wii Sports Res	Wii	2009	Sports	Nintendo	15.75	11.01	3.28	2.96	33

Se realizó una selección de los atributos más relevantes para el proyecto, se listan a continuación:

- NA_Sales (Ventas en Norteamérica): Corresponde al predictor principal.
- Global_Sales (Ventas Totales): Es el "target" o lo que queremos predecir.
- Name, Genre y Platform: Son valores categóricos, estos sirven para que la IA identifique los Outliers y el contexto del juego.

ANÁLISIS EXPLORATORIO

- Identificación de Sesgos: Se detectó que el factor "Tiempo" (años) generaba ruido y una correlación nula ($R = -0.22$).
- Correlación de Pearson: Se identificó una colinealidad fuerte entre las ventas de Norteamérica y las Globales, validando la elección de variables.

LIMPIEZA DE DATOS Y PREPROCESAMIENTO


- Criterio de Exclusión: Eliminación de valores atípicos (como Wii Sports) que no representaban el comportamiento orgánico del mercado (ventas atadas a hardware).
- Resultado: El ajuste del modelo mejoró significativamente, elevando el coeficiente R de -0.22 a 0.84.
- Para optimizar la latencia y el uso de memoria en dispositivos móviles, se seleccionó una muestra aleatoria de $n=100$ registros, conservando la integridad estadística del modelo. (Originalmente el dataset contaba con 16,000 registros)

NORMALIZACIÓN Y ESTRUCTURACIÓN

- Conversión de datos crudos a una estructura de pares ordenados (x, y) para el motor de regresión.
- Escalamiento de valores a "Millones de Unidades" para facilitar la interpretación del modelo.



RESULTADOS

Diseño de la app:



RESULTADOS

Gráficas e interpretación de los datos con Gemini 2.0 Flash



CONCLUSIONES

Este proyecto demuestra la viabilidad de integrar un pipeline completo de Data Science en una plataforma móvil, transformando datos crudos en apoyo para decisiones estratégicas. Se logró un modelo de regresión con un 84% de capacidad predictiva, indicando que el mercado norteamericano es un buen indicador del desempeño global. La principal contribución es la sinergia entre estadística e inteligencia artificial (Gemini 2.0 Flash), que convierte el modelo en una solución automatizada de Business Intelligence altamente precisa.

MUCHAS GRACIAS
:)